

House Prices - Advanced Regression Techniques

Phạm Minh Dương, Nguyễn Đăng Khoa,
Phạm Tấn Đạt, Đỗ Quốc Việt



Mục lục

01

Giới thiệu

02

Dọn dẹp dữ liệu

03

**Phân tích khám
phá dữ liệu**

04

Tiền xử lý dữ liệu

05

**Xây dựng mô hình
và lựa chọn model**

06

Kết quả





01 Giới thiệu


Bối cảnh và mục tiêu

Bối cảnh


Cuộc thi Kaggle dự đoán giá nhà tại Ames, Iowa (79 đặc trưng: diện tích, chất lượng, vị trí). Thách thức: Dữ liệu thiếu, outliers, skew, multicollinearity.

Mục tiêu chính

- Dự đoán giá nhà (SalePrice) bằng ML.
- Đạt RMSE < 0.25 trên validation.
- Cải thiện 10-20% so baseline.
- Tạo submission.csv cho Kaggle.



Tổng quan Dữ liệu




Nguồn Dữ liệu

Bộ dữ liệu Kaggle Ames Housing Dataset.


- **train.csv:** 1460 mẫu, 81 cột
- **test.csv:** 1459 mẫu, 80 cột
- **sample_submission.csv:** Định dạng gửi bài

Đặc điểm Chính

- **Phân loại biến:** 43 biến object (phân loại), 37 biến số (định lượng).
- **Missing Values cao:** Biến Alley thiếu 93.77%, LotFrontage thiếu 17.74%.
- **Skewness SalePrice:** Phân phối lệch phải với độ xiên là 1.88.



Phạm vi và Mục tiêu Định lượng



Mục tiêu Định lượng

- RMSE (sau log transform) < **0.25**
- Hệ số xác định R^2 > **0.915**
- Xếp hạng Kaggle **Top 50%**
- So sánh mô hình $\geq$ **10 mô hình**



Phạm vi Nghiên cứu

- Hồi quy với Học máy có Giám sát
- Tập trung vào Mô hình Dựa trên Cây
- Kỹ thuật Ensemble (Ghép mô hình)



02

Dọn dẹp dữ liệu

Xử lý các cột thiếu giá trị

Thiếu rất nhiều (>1000 dòng)

PoolQC, MiscFeature, Alley, Fence → hầu hết “không có” chứ không phải “thiếu”.

👉 Thay NaN bằng 'None'.

Thiếu nhiều (200–700 dòng)

FireplaceQu, LotFrontage → dùng giá trị trung bình theo Neighborhood.

Thiếu ít (dưới 100 dòng):

Garage*, Bsmt*, MasVnr*, Electrical, SaleType, ...

👉 Điền theo quy tắc từng nhóm (ví dụ GarageYrBlt = YearBuilt, Electrical = mode).

Kết quả sau khi làm sạch

Nội dung	Trước xử lý	Sau xử lý
Cột có giá trị null(train)	19	0
Cột có giá trị null(test)	33	0
Giá trị bất hợp lý	Có	Đã sửa



03

Phân tích khám phá dữ liệu

Tổng quan

Mục tiêu chính của EDA

- Tìm kiếm Insight sâu sắc
- Phát hiện Outliers bất thường
- Đánh giá Correlation giữa các biến

Phương pháp luận

Thực hiện phân tích chi tiết qua file eda.ipynb.

SalePrice


Phân phối lệch phải rõ rệt.

Outliers

Phát hiện bất thường tại LotArea & GrLivArea.

Correlations

OverallQual: **0.79**
GrLivArea: **0.71**



Phân tích Biến Số

LotArea Skewness

- Lệch phải mạnh (Skew: 12.2)
- Cần xử lý để chuẩn hóa phân phối dữ liệu

Phân phối YearBuilt


- Dữ liệu trải rộng từ 1872 - 2010
- Thể hiện lịch sử phát triển bất động sản

Biến đổi Log (SalePrice)

- Giảm đáng kể độ lệch phân phối dữ liệu
- Độ lệch (Skew) giảm từ 1.88 xuống 0.12
- Cải thiện đáng kể hiệu suất và độ ổn định của mô hình dự đoán.

Xác định Outliers (GrLivArea)

- 61 mẫu nhà có GrLivArea > 4000 ft²
- Các giá trị này có thể ảnh hưởng tiêu cực đến mô hình



Phân tích Biến Phân loại

Biến Phân loại


Các biến này phân loại đối tượng thành các nhóm riêng biệt, cần thiết cho phân tích sâu hơn.

Chi tiết OverallQual

- Thang điểm chất lượng vật liệu và hoàn thiện từ 1 (Rất tệ) đến 10 (Rất tốt).
- Giá trị trung bình của toàn bộ dữ liệu là 6.1.

- **Neighborhood:** 25 loại khu vực khác nhau
- **OverallQual:** Thang điểm 1-10 chất lượng tổng thể

"Nhà ở phân khúc chất lượng cao (OverallQual 8-10) có giá bán cao hơn trung bình tới hơn 50%."




Tương quan và Heatmap

Tương quan mạnh
với SalePrice (số
liệu)

OverallQual: **0.79**

GrLivArea: **0.71**

GarageCars: **0.64**




Lưu ý Đa cộng tuyến

- GarageArea & GarageCars: **0.88**
- Vấn đề đa cộng tuyến được phát hiện (VIF > 10).
- Cần xử lý để tránh làm sai lệch mô hình.

**Đặc trưng One-Hot
Encoding đáng chú ý**


MSZoning_RL có tương quan 0.35 với SalePrice, là một trong những đặc trưng one-hot ảnh hưởng nhất.



04

Tiền xử lý dữ liệu

Quy trình tiền xử lý



Khía cạnh Chính

Cải thiện Chất lượng

- Loại bỏ nhiễu và xử lý ngoại lệ hiệu quả.
- Đảm bảo tính nhất quán và độ chính xác của dữ liệu.


Tối ưu hóa Mô hình

- Nâng cao độ chính xác và hiệu suất dự đoán.
- Giảm thiểu thời gian và tài nguyên huấn luyện.

Kỹ thuật Tạo Feature Mới

- TotalSF: Tổng diện tích (BsmtSF + 1stFlrSF + ...)
- HouseAge: Tuổi của căn nhà (YrSold - YearBuilt)
- TotalBath: Tổng số phòng tắm (FullBath + ...)
- Binary Features: Ví dụ `PoolAreaBinary` (có/không)

Minh họa Feature Engineering



Xử lý Missing và Outliers

Xử lý Missing Values

- 19 cột dữ liệu bị thiếu đã được xác định.
- Impute theo ngữ cảnh: Ví dụ, 'Alley' = "None" khi không có ngõ.
- Đảm bảo tính toàn vẹn dữ liệu cho mô hình.

Xử lý Outliers

- Winsorize LotArea: Giới hạn tại phân vị 1% và 99%.
- Loại bỏ 30 outliers: GrLivArea > 4500.
- Cải thiện độ tin cậy và hiệu suất mô hình.

Tóm tắt Hiệu quả Xử lý Dữ liệu

Chỉ số	Tình trạng ban đầu	Sau tiền xử lý
Số cột có Missing Values	19	0
Outliers GrLivArea (>4500)	30	0 (đã loại bỏ)
Outliers LotArea	Giá trị cực đoan	Đã Winsorize (1%-99%)

Feature Engineering

Kỹ thuật Chính


Đặc trưng mới (New Features)

- **TotalSF:** Tổng diện tích sàn. Tương quan **0.78**.
- **HouseAge:** Tuổi của ngôi nhà. Tương quan **-0.52**.
- **MoSold_sin/cos:** Mã hóa chu kỳ tháng bán để nắm bắt yếu tố mùa vụ.

Đặc trưng nhị phân (Binary Features)


- Tạo hơn **20** đặc trưng, ví dụ:
`MasVnrAreaBinary` (có/không vật liệu ốp).

Ma trận tương quan các biến trong kỹ thuật đặc trưng và SalePrice



Kết quả tối ưu hóa mô hình

- Tăng tương quan trung bình 0.1
- Giảm đáng kể đa cộng tuyến



05 Xây dựng mô hình và lựa chọn model

Thử nghiệm Mô hình Cơ bản

Mục tiêu thử nghiệm ban đầu

- Khảo sát khả năng dự đoán của các mô hình cơ bản.
- Thiết lập một đường cơ sở hiệu suất ban đầu.
- Phân tích điểm mạnh, điểm yếu của từng thuật toán.

Linear Regression

- Là mô hình cơ sở để so sánh.
- Đơn giản, dễ giải thích.
- R^2 : **0.85**
- RMSE: **0.30**

Hiệu suất ban đầu

Decision Tree

- Dễ hiểu, trực quan.
- Có nguy cơ bị overfitting cao.
- R^2 : **0.85**
- RMSE: **0.30**

Nguy cơ Overfitting

Random Forest

- Cải thiện đáng kể độ chính xác.
- Giảm thiểu overfitting hiệu quả.
- R^2 : **0.92**
- RMSE: **0.25**

Hiệu suất vượt trội


Thử nghiệm Mô hình Boosting

Mô hình	R ² Score	RMSE	MAE
Gradient Boosting	0.9058	0.2422	0.1611
XGBoost	0.8903	0.2605	0.1737
HGBoost	0.8912	0.2595	0.1783
LightGBM	0.8932	0.2577	0.1784
SVM	0.8995	0.2448	0.1584
CatBoost	0.9024	0.2459	0.1610
KNN	0.8149	0.3414	0.2354

Mô hình Tốt nhất (RMSE)
Gradient Boosting: 0.2422

Ensemble (Stacking)

Stacking Regressor: Kỹ thuật ensemble mạnh mẽ, kết hợp nhiều mô hình cơ sở qua một mô hình meta.



Cấu trúc Mô hình

Mô hình cơ sở :

XGBoost, CatBoost, Random Forest, Gradient Boosting, SVR, LightGBM

Mô hình Meta: LinearRegression

==== Kết quả Stacking Model ====

Train R2: 0.99282

Train MAE: 0.04644

Train RMSE: 0.06784



06

Kết quả

Kaggle Score

RMSE: 0.11903

Đạt vị trí top 20-30% trên bảng xếp hạng Public Leaderboard.

Cải thiện 60%

Hiệu suất mô hình vượt trội so với baseline.



submission.csv

Complete · now · 2

0.11903

RMSE (Root Mean Square Error)

Đo lường độ lớn trung bình của sai số. Chỉ số càng nhỏ, mô hình càng chính xác.

Đánh giá vị trí trên Leaderboard

Vị trí cao trên bảng xếp hạng thể hiện hiệu suất mô hình tốt

THANK YOU

