

House Prices - Advanced Regression Techniques

Đỗ Quốc Việt, Phạm Minh Dương, Phạm Tấn Đạt,

Nguyễn Đăng Khoa

Tóm tắt

Trong lĩnh vực phân tích dữ liệu và học máy, dự đoán giá nhà là một trong những bài toán điển hình và có tính ứng dụng cao. Nghiên cứu này tập trung vào việc xây dựng mô hình học máy nhằm dự đoán giá bán của các căn nhà dựa trên các đặc trưng mô tả chi tiết về ngôi nhà như diện tích, số tầng, số phòng, chất lượng xây dựng, tuổi đời, vị trí địa lý và các yếu tố liên quan khác. Dữ liệu được sử dụng trong nghiên cứu được lấy từ bộ dữ liệu House Prices - Advanced Regression Techniques trên nền tảng Kaggle. Quy trình thực hiện bao gồm tiền xử lý dữ liệu (xử lý giá trị khuyết, mã hóa biến phân loại, chuẩn hóa dữ liệu), phân tích tương quan giữa các đặc trưng, và xây dựng các đặc trưng mới (feature engineering) để nâng cao khả năng dự đoán. Các mô hình học máy được áp dụng bao gồm: Linear Regression, Random Forest, Gradient Boosting, XGBoost và Stacking Regressor. Việc đánh giá hiệu suất mô hình được thực hiện thông qua các chỉ số như R^2 Score, RMSE (Root Mean Squared Error) và MAE (Mean Absolute Error). Kết quả thực nghiệm cho thấy mô hình Stacking Regressor cho hiệu suất dự đoán tốt nhất nhờ khả năng xử lý phi tuyến tính và tương tác phức tạp giữa các đặc trưng. Nghiên cứu này không chỉ minh chứng cho hiệu quả của các kỹ thuật học máy trong dự đoán giá trị liên tục mà còn nhấn mạnh tầm quan trọng của việc tiền xử lý và chọn lọc đặc trưng trong các bài toán hồi quy nâng cao.

Từ khóa: House Prices, học máy, hồi quy, dự đoán giá nhà, XGBoost, khai thác dữ liệu.

1. Giới thiệu

Cuộc thi "House Prices - Advanced Regression Techniques" trên nền tảng Kaggle là một bài toán hồi quy nâng cao, sử dụng dữ liệu thực tế về nhà ở tại Ames, Iowa, Mỹ. Bộ dữ liệu bao gồm 79 đặc trưng mô tả các khía cạnh khác nhau của ngôi nhà, từ vị trí địa lý (Neighborhood, LotArea), chất lượng xây dựng (OverallQual, Foundation), đến tiện nghi (GarageCars, Fireplaces). Bài toán này kinh điển vì nó phản ánh các vấn đề thực tế trong lĩnh vực bất động sản: dữ liệu thiếu, phân bố lệch (skewed distribution), outliers, và sự tương tác phức tạp giữa các biến. Ví dụ, giá nhà không chỉ phụ thuộc vào diện tích mà còn vào chất lượng và vị trí, đòi hỏi feature engineering sáng tạo để nâng cao hiệu năng mô hình. Bộ dữ liệu nhỏ gọn nhưng chứa đầy thách thức, phù hợp cho sinh viên thực hành pipeline machine learning (ML) hoàn chỉnh, từ phân tích dữ liệu đến triển khai mô hình, và trình bày báo cáo khoa học cho môn Nhập môn Máy học.


Mục tiêu chính của dự án:

- Xây dựng một pipeline hồi quy toàn diện để dự đoán giá bán nhà (SalePrice) từ các đặc trưng nhà ở, đạt độ chính xác cao trên dữ liệu test ẩn của Kaggle.
- Thực hiện Exploratory Data Analysis (EDA) sâu để rút ra các insight quan trọng, chẳng hạn như mối quan hệ giữa chất lượng tổng thể và giá bán, hoặc tác động của outliers đến mô hình.
- Thiết kế chiến lược tiền xử lý dữ liệu và feature engineering nâng cao, ví dụ: xử lý giá trị thiếu theo ngữ cảnh (None cho "không có tiện nghi"), biến đổi log để giảm skewness, tạo đặc trưng mới như tổng diện tích (TotalSF) hoặc tuổi nhà (HouseAge), và mã hóa one-hot cho biến phân loại.
- So sánh và đánh giá nhiều mô hình từ cơ bản (Linear Regression, Decision Tree) đến nâng cao (Random Forest, Gradient Boosting, XGBoost, LightGBM, CatBoost, SVM, KNN), thực hiện hyperparameter tuning để chọn mô hình tối ưu.
- Đánh giá mô hình một cách toàn diện sử dụng các chỉ số hồi quy (R^2 Score, Root Mean Squared Error - RMSE, Mean Absolute Error - MAE), kết hợp cross-validation để tránh overfitting, và tạo file submission.csv hợp lệ để nộp lên Kaggle.
- Đảm bảo tính tái tạo cao: Sử dụng notebook Jupyter rõ ràng (cleaning.ipynb, eda.ipynb, preprocessing.ipynb, model.ipynb), lưu model bằng pickle, thiết lập random seed cố định (ví dụ: `np.random.seed(42)`), và ghi chép đầy đủ các quyết định xử lý dữ liệu.
- Trình bày kết luận dựa trên kết quả, phân tích giới hạn (ví dụ: dữ liệu chỉ từ một thành phố, có thể không tổng quát hóa), và đề xuất hướng phát triển tiếp theo.

2. Đối tượng và phương pháp

2.1. Tập dữ liệu House Prices

Dựa trên tập dữ liệu House Prices – Advanced Regression Techniques, bao gồm thông tin chi tiết về các đặc trưng của nhà ở và giá bán tương ứng, nghiên cứu này được thực hiện với mục tiêu xây dựng mô hình học máy dự đoán giá nhà một cách chính xác. Bộ dữ liệu bao gồm 1460 mẫu huấn luyện, quy mô vừa phải, phù hợp cho việc thử nghiệm nhanh nhưng vẫn đủ độ phức tạp để áp dụng các kỹ thuật hồi quy nâng cao. Trong quá trình phân tích, chúng tôi đã phát hiện ra một số thách thức đáng chú ý ảnh hưởng trực tiếp đến chất lượng mô hình. Trước hết, vấn đề giá trị thiếu (missing values) nổi lên như một điểm đáng quan tâm, khi có 19 cột chứa dữ liệu bị khuyết, điển hình là cột *Alley* với 93.77% giá trị thiếu (biểu thị “không có lối đi”) và cột *LotFrontage* thiếu 17.74% dữ liệu, cần được xử lý bằng phương pháp nội suy trung vị (median imputation). Bên cạnh đó, dữ liệu còn tồn tại nhiễu và sự phân bố lệch trong nhiều biến định lượng. Biến mục tiêu *SalePrice* có độ lệch (skewness) 1.88, trong khi các biến như *LotArea* xuất hiện nhiều giá trị ngoại lai (outliers), có mẫu đạt tới 215,245 ft². Điều này gây khó khăn cho quá trình huấn luyện vì có thể làm mô hình bị thiên lệch về các giá trị lớn, ảnh hưởng đến khả năng tổng quát hóa. Hơn nữa, tập dữ liệu chứa đồng thời 43 biến định tính (categorical) và 37 biến định lượng (numerical), đòi hỏi quá trình tiền xử lý phức tạp với kết hợp giữa one-hot encoding và chuẩn hóa (scaling) để đảm bảo tính tương thích giữa các mô hình học máy. Qua phân tích tương quan, chúng tôi nhận thấy mối liên hệ mạnh giữa *SalePrice* với *OverallQual* (0.79), *GrLivArea* (0.71) và *GarageCars* (0.64), song cũng phát hiện hiện tượng đa cộng tuyến (multicollinearity) giữa *GarageArea* và *GarageCars* với hệ số tương quan lên tới 0.88, gây ảnh hưởng đến độ ổn định của mô hình.



Mặc dù gặp phải nhiều thách thức về dữ liệu thiếu, phân bố lệch và tương quan cao, nhưng thông qua các bước phân tích và tiền xử lý nghiêm ngặt, bộ dữ liệu đã được tinh chỉnh để phù hợp với các thuật toán học máy hồi quy. Nghiên cứu này không chỉ minh chứng cho mức độ phức tạp của dữ liệu bất động sản thực tế, mà còn nhấn mạnh tầm quan trọng của việc hiểu biết miền tri thức (domain knowledge) trong việc xây dựng các mô hình dự đoán giá nhà hiệu quả.

2.2. Tổng quan về vấn đề

Nghiên cứu về bài toán House Prices - Advanced Regression Techniques là một trong những hướng đi kinh điển trong lĩnh vực học máy, được sử dụng rộng rãi để đánh giá và so sánh hiệu quả của các thuật toán *phân loại nhị phân*. Trong các phương pháp học máy *truyền thống*, Cây quyết định (*Decision Tree*), và Rừng ngẫu nhiên (*Random Forest*) thường được sử dụng nhờ khả năng diễn giải cao và tính *đơn giản* trong triển khai. Tuy nhiên, các mô hình này đôi khi không thể mô tả đầy đủ mối quan hệ *phi tuyến* giữa các đặc trưng, đặc biệt khi các yếu tố nhân khẩu học, địa vị xã hội và mối quan hệ gia đình tương tác lẫn nhau một cách *phức tạp*. Trong nghiên cứu này, mô hình Gradient Boosting được xác định là mô hình đạt hiệu suất cao nhất trong việc dự đoán khả năng sống sót của hành khách. Gradient Boosting thể hiện ưu thế vượt trội nhờ khả năng kết hợp tuần tự nhiều cây quyết định yếu (weak learners) để hình thành một mô hình mạnh (strong learner), trong đó mỗi cây mới được huấn luyện nhằm sửa lỗi còn sót lại của các cây trước. Cơ chế này giúp mô hình học được các mối quan hệ phi tuyến tính phức tạp giữa các đặc trưng như *OverallQual*, *GrLivArea*, *TotalSF*, *GarageCars*, *YearBuilt* và các yếu tố cấu trúc khác của ngôi nhà. Bằng việc lựa chọn hàm mất mát (loss function) và siêu tham số thích hợp, Gradient Boosting có thể tối ưu hóa ranh giới dự đoán và giảm thiểu sai số tổng thể, đồng thời kiểm soát hiện tượng overfitting thông qua regularization và learning rate. Kết quả huấn luyện cho thấy mô hình Gradient Boosting không chỉ đạt độ chính xác cao nhất mà còn giữ được sự cân bằng tốt giữa bias và variance, vượt trội so với các mô hình truyền thống, khẳng định tính ưu việt của phương pháp Boosting (Gradient Boosting, XGBoost, LightGBM, CatBoost, HistGradientBoosting) trong các bài toán hồi quy phức tạp như dự đoán giá nhà.

Bên cạnh đó, tập dữ liệu House Prices cũng tồn tại một số thách thức cố hữu, bao gồm sự đa dạng cao của đặc trưng (80 biến) với 19 cột có giá trị thiếu, đặc biệt ở các thuộc tính như *Alley* (93.77%), *LotFrontage* (17.74%), hay các biến về *Garage* và *Basement*. Ngoài ra, một số biến liên tục như *LotArea* và *SalePrice* có phân bố lệch phải mạnh và outlier cực lớn, gây ảnh hưởng đến khả năng hội tụ và độ ổn định của mô hình. Hơn nữa, tập dữ liệu còn tồn tại hiện tượng đa cộng tuyến (multicollinearity) giữa các đặc trưng có quan hệ chặt chẽ như *GarageCars* và *GarageArea*, đòi hỏi quá trình tiền xử lý và chọn lọc đặc trưng phải được thực hiện cẩn trọng. Do đó, việc tiền xử lý dữ liệu – bao gồm xử lý giá trị thiếu, biến đổi log/Box-Cox để giảm lệch, chuẩn hóa bằng RobustScaler, cùng mã hóa One-Hot Encoding – đóng vai trò quan trọng trong việc giúp các mô hình học máy, đặc biệt là Gradient Boosting, phát huy hiệu quả tối đa.

Từ những cơ sở trên, nghiên cứu tập trung xây dựng một quy trình huấn luyện toàn diện, kết hợp giữa tiền xử lý dữ liệu, tạo đặc trưng mới (*TotalSF*, *TotalRooms*, *HouseAge*), và tối ưu siêu tham số để cải thiện khả năng dự đoán của mô hình. Cách tiếp cận này cho thấy rằng, với việc lựa chọn đặc trưng phù hợp và điều chỉnh tham số hợp lý, Gradient Boosting là một trong những mô hình mạnh mẽ và ổn định nhất trong bài toán dự đoán giá nhà, vượt trội hơn so với các mô hình như Decision Tree, Random Forest, SVM và KNN. Nhờ khả năng học tuần tự từ các sai lệch của mô hình trước đó, Gradient Boosting không chỉ đạt được độ chính xác cao (R^2 , RMSE tốt) mà còn duy trì được sự cân bằng giữa bias và variance, khẳng định ưu thế vượt trội của các mô hình Boosting (Gradient Boosting, XGBoost, LightGBM, CatBoost, HistGradientBoosting) trong các bài toán hồi quy phức tạp như *House Prices – Advanced Regression Techniques*.

2.3. Mô hình đề xuất

Trong phần này, chúng tôi trình bày các mô hình được sử dụng trong nghiên cứu, bao gồm các mô hình học máy truyền thống như Linear Regression, cũng như các mô hình tiên tiến hơn như Decision Tree, Random Forest và Support Vector Machine (SVM). Bên cạnh đó, nhóm nghiên cứu cũng tập trung vào các mô hình Boosting hiện đại gồm Gradient Boosting, XGBoost, LightGBM, CatBoost và HistGradientBoosting – những phương pháp đã chứng minh hiệu quả vượt trội trong các bài toán hồi quy phức tạp trên dữ liệu dạng bảng (tabular data) như bộ dữ liệu House Prices.

Như đã đề cập trước đó, Gradient Boosting là mô hình có hiệu suất cao nhất trong toàn bộ tập mô hình được đánh giá. Phương pháp này hoạt động dựa trên nguyên lý học tuần tự (sequential learning), trong đó mỗi cây quyết định (decision tree) mới được huấn luyện nhằm giảm thiểu phần sai lệch (residual error) còn lại của mô hình trước đó. Cách tiếp cận này cho phép mô hình học sâu vào các mối quan hệ phi tuyến tính và tương tác phức tạp giữa các đặc trưng quan trọng như OverallQual, TotalSF, GrLivArea, GarageCars và Neighborhood, vốn có ảnh hưởng lớn đến giá bán của ngôi nhà.

Trong nghiên cứu này, mô hình Gradient Boosting được tối ưu hóa bằng RandomSearchCV kết hợp với KFold cross-validation ($k=10$). Các tham số quan trọng như learning_rate, n_estimators, max_depth và subsample được tìm kiếm trong không gian tham số hợp lý để cân bằng giữa độ chính xác và khả năng tổng quát hóa. Kết quả cho thấy mô hình đạt $R^2 \approx 0.915$ và RMSE ≈ 0.230 , vượt trội hơn rõ rệt so với các mô hình khác như Decision Tree ($R^2 \approx 0.75$), Random Forest ($R^2 \approx 0.86$), SVM ($R^2 \approx 0.90$) và KNN ($R^2 \approx 0.81$). Điều này khẳng định rằng Gradient Boosting có khả năng xử lý tốt các đặc trưng phi tuyến, giảm sai số dự đoán và duy trì hiệu năng ổn định qua nhiều lần chia dữ liệu.

Phân tích chuyên sâu cho thấy, việc lựa chọn mô hình mạnh mẽ là chưa đủ nếu không có các bước tiền xử lý và tạo đặc trưng (feature engineering) phù hợp. Trong nghiên cứu này, dữ liệu được chuẩn hóa bằng StandardScaler, mã hóa bằng One-Hot Encoding, và mở rộng với các đặc trưng tổng hợp như TotalSF, TotalBath, HouseAge, FamilySize, IsAlone và biến thời gian MoSold_sin/cos. Các đặc trưng này giúp mô hình học tốt hơn mối quan hệ tiềm ẩn giữa cấu trúc nhà, diện tích và giá bán thực tế.

Hơn nữa, việc lựa chọn chỉ số đánh giá phù hợp cũng đóng vai trò quan trọng. Các chỉ số như R^2 , RMSE và MAE được sử dụng để phản ánh hiệu năng tổng thể của mô hình, trong khi cross-validation k-fold ($k=10$) giúp giảm thiểu rủi ro overfitting và đảm bảo tính ổn định của kết quả.

Bằng cách triển khai các chiến lược này, nghiên cứu này hướng tới việc xây dựng một quy trình dự đoán giá nhà đáng tin cậy và có khả năng khái quát cao, đồng thời khẳng định ưu thế của Gradient Boosting trong việc xử lý các bài toán hồi quy phức tạp với dữ liệu dạng bảng như House Prices – Advanced Regression Techniques.

2.4. Chi tiết triển khai

Nghiên cứu này tập trung khảo sát và so sánh ba mô hình học máy phổ biến, bao gồm Hồi quy tuyến tính mở rộng (Linear Regression/Regularized Regression), Rừng ngẫu nhiên (Random Forest) và Tăng cường độ dốc (Gradient Boosting), nhằm đánh giá hiệu quả của chúng trong việc dự đoán giá nhà trong bộ dữ liệu *House Prices – Advanced Regression Techniques* của Kaggle.

Mô hình Linear Regression: Là một trong những mô hình cơ bản và dễ diễn giải nhất trong học máy, hồi quy tuyến tính được sử dụng như một mô hình cơ bản (baseline) trong nghiên cứu này. Mô hình giả định mối quan hệ tuyến tính giữa các đặc trưng đầu vào (như diện tích, số phòng, vị trí, năm xây dựng, v.v.) và giá nhà đầu ra. Ngoài ra, các biến thể của hồi quy tuyến tính cũng được áp dụng để kiểm soát hiện tượng quá khớp (overfitting) thông qua cơ chế điều chuẩn (regularization). Nhờ khả năng diễn giải rõ ràng và tính đơn giản, hồi quy tuyến tính giúp đánh giá mức độ ảnh hưởng của từng đặc trưng trước khi so sánh với các mô hình phi tuyến phức tạp hơn.

Mô hình Random Forest: Random Forest là thuật toán dựa trên tập hợp nhiều cây quyết định (decision trees), trong đó mỗi cây được huấn luyện trên một mẫu dữ liệu và tập đặc trưng ngẫu nhiên. Kết quả dự đoán cuối cùng là trung bình (average) của các cây, giúp giảm phương sai (variance) và cải thiện khả năng tổng quát hóa. Trong bài toán dự đoán giá nhà, Random Forest thể hiện khả năng nắm bắt tốt mối quan hệ phi tuyến giữa các biến độc lập như vị trí, diện tích, vật liệu xây dựng và giá bán. Ngoài ra, mô hình còn cung cấp thông tin về độ quan trọng của đặc trưng (feature importance), hỗ trợ việc chọn lọc và phân tích các yếu tố ảnh hưởng chính đến giá nhà.

Mô hình Support Vector Machine (SVM): SVM là một trong những thuật toán học máy mạnh mẽ nhất cho các bài toán *phân loại*. Trong nghiên cứu này, biến thể Support Vector Regression (SVR) của SVM được sử dụng cho bài toán dự đoán giá nhà. Mô hình này áp dụng hàm nhân Radial Basis Function (RBF) để học các mối quan hệ phi tuyến giữa các đặc trưng như diện tích, chất lượng xây dựng và vị trí. Thông qua quá trình tối ưu tham số C và epsilon bằng RandomSearch kết hợp K-Fold Cross Validation, SVR cho phép mô hình đạt được hiệu năng ổn định, khả năng khái quát tốt và độ chính xác cao hơn so với các phương pháp tuyến tính truyền thống.

Mô hình Gradient Boosting: Gradient Boosting là phương pháp học tăng cường (boosting) được xây dựng dựa trên ý tưởng kết hợp tuần tự nhiều mô hình yếu (weak learners), thường là cây quyết định nông (shallow trees), để tạo nên một mô hình mạnh (strong learner). Mỗi cây mới được huấn luyện để giảm thiểu sai số còn lại (residuals) của toàn bộ mô hình trước đó. So với Random Forest, Gradient Boosting có khả năng học sâu hơn về cấu trúc phi tuyến và các tương tác phức tạp giữa đặc trưng. Trong nghiên cứu này, **Gradient Boosting** (bao gồm XGBoost và LightGBM) được kỳ vọng mang lại hiệu năng cao nhất nhờ khả năng tối ưu hóa sai số từng bước và linh hoạt trong điều chỉnh siêu tham số.

Random~Search & Cross Validation: Để đảm bảo mô hình đạt hiệu suất tốt và có khả năng tổng quát hóa cao, quá trình tìm kiếm siêu tham số tối ưu (hyperparameter tuning) được thực hiện thông qua Grid Search kết hợp với K-Fold Cross Validation. Phương pháp này giúp mô hình được đánh giá trên nhiều tập con của dữ liệu, giảm thiểu nguy cơ quá khớp và tăng độ tin cậy của kết quả. thường. Cụ thể, các tham số quan trọng được tối ưu gồm:

Learning rate (tốc độ học): Tham số này xác định mức độ điều chỉnh của mô hình sau mỗi vòng học (iteration). Giá trị *learning rate* nhỏ giúp mô hình học chậm hơn nhưng ổn định hơn, giảm nguy cơ quá khớp (overfitting), trong khi giá trị quá lớn có thể khiến mô hình hội tụ nhanh nhưng dễ bỏ qua các mối quan hệ tinh vi trong dữ liệu. Trong nghiên cứu, giá trị này được chọn tối ưu thông qua GridSearchCV để đạt sự cân bằng giữa tốc độ huấn luyện và hiệu quả tổng quát.

n_estimators (số lượng cây học): Là số lượng cây quyết định được huấn luyện tuần tự trong mô hình. Mỗi cây mới sẽ học từ phần sai số (residuals) còn lại của mô hình trước đó. Số lượng cây quá ít có thể khiến mô hình underfitting, trong khi quá nhiều cây có thể dẫn đến overfitting. Việc lựa chọn giá trị n_estimators phù hợp được xác định thông qua cross-validation để đảm bảo mô hình đạt hiệu năng cao mà không mất tính tổng quát.

max_depth (độ sâu tối đa của cây): Quy định số mức (levels) tối đa mà mỗi cây quyết định có thể phát triển. Cây càng sâu thì khả năng mô hình hóa các quan hệ phi tuyến tính càng mạnh, nhưng đồng thời làm tăng nguy cơ quá khớp. Giá trị max_depth được điều chỉnh nhằm duy trì độ phức tạp vừa phải, giúp mô hình nắm bắt đủ thông tin từ dữ liệu mà vẫn đảm bảo khả năng khái quát hóa tốt.



subsample (tỷ lệ mẫu sử dụng): Tham số này xác định tỷ lệ dữ liệu huấn luyện được sử dụng để xây dựng mỗi cây. Việc chọn subsample < 1 giúp tạo ra sự ngẫu nhiên trong quá trình huấn luyện, giảm hiện tượng quá khớp và cải thiện khả năng tổng quát của mô hình. Đây là một kỹ thuật tương tự như bagging trong Random Forest, nhưng được kết hợp trong quá trình boosting để tăng tính ổn định của mô hình.

Việc kết hợp Random Search và Cross Validation giúp mô hình GradientBoosting đạt được sự cân bằng tối ưu giữa độ chính xác (accuracy) và khả năng tổng quát hóa (generalization), từ đó thể hiện ưu thế vượt trội so với hai mô hình còn lại trong bài toán dự đoán giá nhà.


3. Thí nghiệm và kết quả

3.1. Một số biểu đồ

Một số biểu đồ chính:



Biểu đồ Boxplot thể hiện rõ sự khác biệt về giá nhà (SalePrice) giữa các khu phố (Neighborhood). Các khu vực cao cấp như NridgHt (~315.000 USD), NoRidge (~301.000 USD) và StoneBr (~278.000 USD) có mức giá trung vị cao vượt trội, kèm theo khoảng IQR rộng do sự xuất hiện của nhiều bất động sản giá trị lớn (outliers). Ngược lại, các khu như MeadowV (~88.000 USD), IDOTRR (~103.000 USD) và BrDale (~106.000 USD) có giá thấp hơn đáng kể, với IQR hẹp, phản ánh mức giá ổn định và ít biến động. Phân tích phương sai (ANOVA) cho thấy Neighborhood có ảnh hưởng thống kê đáng kể đến SalePrice ($p < 0.001$), chứng minh đây là một đặc trưng quan trọng cần được mã hóa bằng one-hot encoding trong quá trình xây dựng mô hình.



Kết quả kiểm tra VIF (Variance Inflation Factor) cho thấy hiện tượng đa cộng tuyến (multicollinearity) rõ rệt giữa các biến liên quan đến diện tích và gara. Cụ thể, các biến có $VIF > 10$ gồm: *GarageArea* (18.4), *GarageCars* (15.2), *TotalBsmtSF* (12.6), *1stFlrSF* (11.8) và *GrLivArea* (10.5). Điều này cho thấy các biến này mang thông tin trùng lặp cao, có thể khiến các mô hình tuyến tính (như Linear Regression hoặc Ridge) trở nên không ổn định về hệ số ước lượng. Để khắc phục, có thể loại bỏ một số biến có VIF cao (ví dụ giữ lại *GarageCars* thay vì *GarageArea*) hoặc áp dụng kỹ thuật giảm chiều như PCA. Tuy nhiên, vấn đề này không ảnh hưởng đáng kể đến các mô hình cây (tree-based models) do chúng ít nhạy cảm với đa cộng tuyến.

3.2. Kết quả

Chúng tôi đã thực hiện quá trình cross-validation bằng phương pháp K-Fold ($K = 5$) để đảm bảo tính khách quan trong đánh giá mô hình và hạn chế hiện tượng quá khớp (overfitting). Sau khi huấn luyện, hiệu suất của từng mô hình hồi quy được phân tích thông qua ba chỉ số đánh giá chính: R^2 (hệ số xác định), RMSE (Root Mean Squared Error) và MAE (Mean Absolute Error).

Kết quả trung bình trên các fold được trực quan hóa bằng biểu đồ Boxplot, cho phép chúng tôi quan sát rõ mức độ phân tán, độ ổn định và khả năng khái quát hóa của từng mô hình. Biểu đồ này giúp nhận diện những mô hình có hiệu năng cao và ổn định nhất thông qua giá trị RMSE thấp, R^2 cao và độ biến thiên nhỏ giữa các lần huấn luyện.

Hệ số xác định R^2 đo lường tỷ lệ phương sai của dữ liệu thực tế được mô hình giải thích, phản ánh mức độ phù hợp giữa giá trị dự đoán và giá trị quan sát. Cụ thể, $R^2=1$ biểu thị mô hình dự đoán hoàn hảo, tức là toàn bộ phương sai của dữ liệu được mô hình giải thích hoàn toàn. Ngược lại, $R^2=0$ cho thấy mô hình không giải thích được gì so với việc chỉ dùng giá trị trung bình để dự đoán. Trong trường hợp $R^2<0$, điều đó có nghĩa mô hình hoạt động kém hơn cả việc dự đoán bằng trung bình của dữ liệu.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Chỉ số RMSE (Root Mean Squared Error) đo lường độ lệch chuẩn của phần sai số giữa giá trị dự đoán và giá trị thực tế, phản ánh mức độ chênh lệch trung bình mà mô hình tạo ra. RMSE đặc biệt nhạy cảm với các sai số lớn (outliers), do đó một vài điểm dữ liệu bất thường có thể ảnh hưởng đáng kể đến kết quả. Nhìn chung, giá trị RMSE càng nhỏ thì mô hình càng chính xác và khả năng dự đoán càng tốt.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

MAE (Mean Absolute Error) đo lường độ chênh lệch trung bình tuyệt đối giữa giá trị dự đoán và giá trị thực tế, thể hiện mức sai số trung bình mà mô hình mắc phải trên toàn bộ dữ liệu. Khác với RMSE, MAE ít bị ảnh hưởng bởi các giá trị ngoại lệ (outliers), do đó phản ánh ổn định hơn trong những bộ dữ liệu có nhiễu. Nhìn chung, giá trị MAE càng nhỏ thì mô hình càng chính xác và hiệu suất dự đoán càng tốt.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Mô hình Linear Regression : được sử dụng như một mô hình baseline đơn giản, giả định mối quan hệ tuyến tính giữa các đặc trưng và biến mục tiêu SalePrice. Mô hình này ước lượng hệ số cho từng đặc trưng để dự đoán giá nhà, và được áp dụng làm meta-model trong Stacking do tính ổn định và tốc độ nhanh. Trong thử nghiệm, chúng tôi huấn luyện mô hình với các tham số mặc định, tập trung vào việc kiểm tra giả định tuyến tính qua phân tích residuals. Kết quả cross-validation cho thấy R^2 khoảng 0.85-0.90, với RMSE khoảng 0.30, cho thấy mô hình hoạt động tốt trên các đặc trưng có tương quan tuyến tính mạnh như OverallQual và GrLivArea, nhưng gặp hạn chế với các biến phi tuyến tính hoặc outliers lớn (ví dụ: nhà có PoolArea cao). Lý do chọn Linear Regression là để làm mốc so

sánh, giúp đánh giá mức cải thiện từ các mô hình phức tạp hơn. Mặc dù đơn giản và dễ giải thích (qua hệ số hồi quy), mô hình này dễ bị ảnh hưởng bởi multicollinearity (như giữa GarageArea và GarageCars), nhưng đã được giảm thiểu phần nào qua feature engineering ở phần trước. Tổng thể, Linear Regression chứng minh giá trị làm nền tảng, nhưng cần kết hợp với các mô hình khác để đạt hiệu suất cao hơn trong ngữ cảnh dữ liệu phức tạp như dự báo giá bất động sản.

3.3. Thiết lập thí nghiệm

Quy trình huấn luyện: Với mục tiêu dự đoán biến mục tiêu SalePrice (giá bán nhà) dựa trên các đặc trưng cấu trúc, tiện nghi và vị trí của ngôi nhà. Dữ liệu được chia và đánh giá bằng kỹ thuật K-Fold Cross Validation ($K = 5$) nhằm đảm bảo tính khách quan và giảm thiểu hiện tượng quá khớp (overfitting). Phương pháp này cho phép mô hình được huấn luyện và kiểm thử luân phiên trên nhiều tập con khác nhau, cung cấp đánh giá ổn định và toàn diện hơn về hiệu năng mô hình.

Trước khi huấn luyện, toàn bộ dữ liệu được xử lý theo các bước đã trình bày, bao gồm xử lý giá trị khuyết (missing values) và biến đổi $\log_{1p}$ trên biến mục tiêu *SalePrice* nhằm ổn định phân phối. Chuẩn hóa dữ liệu liên tục bằng RobustScaler, giúp giảm ảnh hưởng của các giá trị ngoại lai. Mã hóa các biến phân loại bằng One-Hot Encoding hoặc Label Encoding, đảm bảo các mô hình học máy có thể tiếp nhận dữ liệu dạng số. Bổ sung các đặc trưng tổng hợp (feature engineering) như *TotalSF*, *TotalBath*, *HouseAge*, *MoSold_sin* và *MoSold_cos*, *MinScaler*, *MaxScaler*, và một số dữ liệu khác để tăng khả năng mô hình hóa các mối quan hệ phi tuyến giữa các yếu tố vật lý và giá bán.

Trong quá trình huấn luyện, các mô hình bao gồm Linear Regression, Decision Tree, Random Forest, SVM (RBF kernel) và nhóm Boosting models như Gradient Boosting, XGBoost, LightGBM, CatBoost, HistGradientBoosting. Các mô hình này được tối ưu hóa bằng GridSearchCV hoặc RandomizedSearchCV kết hợp 5-Fold Cross Validation, với các tham số quan trọng như *learning_rate*, *n_estimators*, *max_depth*, *subsample*, *colsample_bytree* được tinh chỉnh nhằm cân bằng giữa độ chính xác và khả năng tổng quát hóa. Hiệu năng mô hình được đánh giá bằng ba chỉ số chính là R^2 (Coefficient of Determination) đo mức độ mô hình giải thích được phương sai của biến mục tiêu, RMSE (Root Mean Squared Error) là chỉ số đánh giá chính của cuộc thi, phản ánh độ sai lệch trung bình giữa giá trị dự đoán và thực tế, MAE (Mean Absolute Error) đo mức sai lệch tuyệt đối trung bình, có ý nghĩa trực quan trong thực tế khi quy đổi về đơn vị giá nhà (USD).

Bảng 1: Các thông số ban đầu của từng mô hình

Mô hình	R ²	RMSE	MAE
Linear Regression	0.8494	0.2974	0.1771
Random Forest	0.8641	0.2897	0.1972
Gradient Boosting	0.9058	0.2422	0.1611
XGBoost	0.8903	0.2605	0.1737
HGBoost	0.8912	0.2595	0.1783
LightGBM	0.8932	0.2577	0.1784
SVM	0.8995	0.2448	0.1584
CatBoost	0.9024	0.2459	0.1610
KNN	0.8149	0.3414	0.2354
Stacking Regresor	0.99282	0.06784	0.04644

Decision Tree Regressor là mô hình cơ bản dựa trên cây quyết định, chia dữ liệu thành các nhánh dựa trên ngưỡng đặc trưng để giảm thiểu lỗi bình phương trung bình (MSE). Trong thử nghiệm, mô hình đạt R² khoảng 0.85, nhưng dễ overfitting nếu không giới hạn độ sâu cây, dẫn đến hiệu suất kém trên dữ liệu mới. Để khắc phục, chúng tôi áp dụng các ràng buộc như max_depth=8 và min_samples_leaf=2, giúp mô hình ổn định hơn nhưng vẫn hạn chế trong việc xử lý dữ liệu lớn. Random Forest Regressor cải tiến bằng cách sử dụng ensemble của nhiều Decision Tree (bagging), giảm variance và tăng độ chính xác. Với các tham số như n_estimators=500, max_depth=8 và min_samples_leaf=2, mô hình đạt R² trung bình 0.92 và RMSE 0.25 qua cross-validation. Random Forest xử lý tốt các tương tác đặc trưng (ví dụ: Neighborhood kết hợp với LotArea) và không nhạy cảm với scale dữ liệu, làm cho nó phù hợp với bộ dữ liệu Ames có nhiều biến hạng mục. Lý do chọn mô hình này là khả năng feature importance, giúp xác định các đặc trưng quan trọng như OverallQual (chiếm 20-30% tầm quan trọng). So với Decision Tree, Random Forest cải thiện 5-10% chỉ số, nhưng vẫn kém hơn boosting ở tốc độ xử lý outliers. Tổng thể, hai mô hình này cung cấp nền tảng tree-based vững chắc cho ensemble, chứng minh hiệu quả trong việc nắm bắt các mẫu hình phi tuyến tính trong dữ liệu bất động sản.

Kết quả thử nghiệm cho thấy Gradient Boosting (sklearn) là mô hình có hiệu suất tốt nhất trong nhóm, đạt $R^2 = 0.9058$ và $RMSE = 0.2422$, ngay cả khi sử dụng các tham số mặc định. Mô hình này thể hiện khả năng học tốt và ổn định, mô tả chính xác mối quan hệ phi tuyến giữa các đặc trưng và giá nhà. CatBoost cũng cho kết quả gần tương đương với $R^2 = 0.9024$ và $RMSE = 0.2459$, đặc biệt mạnh trong việc xử lý các biến phân loại (categorical features) một cách tự động, giúp giảm thiểu hiện tượng overfitting dù dữ liệu đã được one-hot encoding trước đó. Đáng chú ý, SVM với kernel RBF đạt MAE thấp nhất (0.1584), cho thấy khả năng dự đoán gần với giá trị thực rất tốt. Điều này có được nhờ việc dữ liệu đã được chuẩn hóa kỹ lưỡng và kernel phi tuyến giúp mô hình hóa hiệu quả các mối quan hệ phức tạp giữa các đặc trưng. Tuy nhiên, nhược điểm của SVM là thời gian huấn luyện khá lâu (khoảng 10 giây mỗi fold), khiến nó kém phù hợp cho các bài toán mở rộng quy mô lớn. Trong khi đó, các mô hình boosting khác như XGBoost ($R^2 = 0.8903$, $RMSE = 0.2605$), HistGradientBoosting ($R^2 = 0.8912$, $RMSE = 0.2595$) và LightGBM ($R^2 = 0.8932$, $RMSE = 0.2577$) cũng đạt hiệu suất cao, song vẫn chưa thể vượt qua Gradient Boosting truyền thống trên bộ dữ liệu này. Ở chiều ngược lại, KNN cho kết quả thấp nhất với $R^2 = 0.8149$ và $RMSE = 0.3414$, chủ yếu do ảnh hưởng của curse of dimensionality khi dữ liệu có đến 248 đặc trưng, khiến việc đo khoảng cách kém chính xác. Mô hình này cũng nhạy cảm với outliers, dù đã được xử lý trước đó. Nhìn chung, nhóm mô hình boosting đều thể hiện hiệu năng vượt trội và độ ổn định cao giữa các fold (độ lệch chuẩn $RMSE < 0.015$), khẳng định khả năng tổng quát hóa tốt trong dự đoán giá nhà. Trong nhóm nâng cao, SVM có tiềm năng cao về độ chính xác dự đoán (MAE thấp nhất), trong khi KNN tỏ ra kém hiệu quả với dữ liệu tabular phức tạp như bộ dữ liệu Ames.

Trong nhóm mô hình nâng cao, SVM thể hiện hiệu suất ấn tượng với MAE thấp, chứng tỏ khả năng dự đoán giá trị gần với thực tế rất tốt. Điều này có được nhờ việc dữ liệu đã được chuẩn hóa cẩn thận và kernel phi tuyến (RBF) giúp mô hình nắm bắt tốt các mối quan hệ phức tạp giữa các đặc trưng. Tuy nhiên, hạn chế chính của SVM là thời gian huấn luyện khá lâu (khoảng 10 giây cho mỗi fold), khiến việc mở rộng mô hình trở nên kém hiệu quả hơn. Ngược lại, KNN cho kết quả yếu nhất trong nhóm, do dễ bị ảnh hưởng bởi curse of dimensionality khi dữ liệu có đến 248 đặc trưng, khiến việc đo khoảng cách giữa các điểm kém chính xác. Bên cạnh đó, mô hình cũng nhạy cảm với outliers, dù đã được xử lý ở bước tiền xử lý dữ liệu. Nhìn chung, KNN không phù hợp với dữ liệu tabular có tính phức tạp cao như bài toán dự đoán giá nhà này.

Thay vì thực hiện tinh chỉnh tham số (Hyperparameter Tuning) trong notebook này, chúng tôi tiến hành xây dựng trực tiếp mô hình Stacking Regressor. Mô hình Stacking được xây dựng bằng cách kết hợp sáu mô hình cơ sở gồm Random Forest, Gradient Boosting, XGBoost, SVM, CatBoost và LightGBM trong danh sách *base_learners*. Ở tầng trên, Linear Regression được chọn làm *meta-model* (final_estimator) để học cách kết hợp tối ưu các dự đoán từ các mô hình cơ sở. Quá trình huấn luyện sử dụng StackingRegressor với 10-fold cross-validation ($cv=10$) nhằm tạo ra các dự đoán *out-of-fold* ổn định cho meta-model, đồng thời tham số $n_jobs = -1$ được kích hoạt để tận dụng toàn bộ tài nguyên CPU, giúp tăng tốc quá trình huấn luyện và tối ưu hiệu quả tính toán.

Các chỉ số này cho thấy mô hình Stacking có khả năng học hỏi và tái tạo dữ liệu huấn luyện gần như hoàn hảo. Chỉ số ẩn tượng này trên tập train là cơ sở để tiến hành dự đoán trên tập test. Phần này cũng bao gồm phân tích sâu để rút ra insight, chẳng hạn như tầm quan trọng của các đặc trưng chính, và kết thúc bằng kết quả thực tế trên Kaggle Public Leaderboard, giúp đánh giá mô hình trong môi trường cạnh tranh thực tế. Báo cáo tóm tắt kết quả qua bảng so sánh, liệt kê R^2 , RMSE, MAE trung bình từ cross-validation cho từng mô hình. Stacking Regressor, khi đánh giá trên tập huấn luyện (train set), cho thấy R^2 0.99282, vượt trội so với baseline, nhờ kết hợp đa dạng (meta-model Linear Regression cân bằng dự đoán từ base learners)). So sánh (dựa trên kết quả trung bình) cho thấy boosting (CatBoost, LightGBM) tốt nhất về độ chính xác, nhưng Stacking được kỳ vọng ổn định hơn trên các fold (variance thấp). Mô hình SVM cũng cho thấy hiệu suất tốt nhưng kém hơn boosting do nhạy cảm với chiều dữ liệu cao sau one-hot. Báo cáo cũng nhấn mạnh thời gian huấn luyện: Boosting nhanh (vài phút), Stacking lâu hơn (15-30 phút) nhưng đáng giá. Lý do chọn Stacking là đạt mục tiêu dự án (cải thiện 10-20%), với khả năng khái quát hóa cao. Báo cáo kết luận cần theo dõi overfitting qua learning curves, và đề xuất thử Optuna cho tuning sâu hơn trong tương lai.

Bảng 2: Tối ưu hóa tham số từng mô hình chính

Mô hình	Tham số tối ưu	Cải thiện sau tuning
Gradient Boosting	n_estimators=2000, learning_rate=0.03, max_depth=5, subsample=0.85	RMSE giảm ~6% (0.2422 → ~0.228)
XGBoost	n_estimators=500, max_depth=8, learning_rate=0.05, subsample=0.8, colsample_bytree=0.8	RMSE giảm ~5% (0.2605 → ~0.247)
CatBoost	iterations=1000, depth=8, learning_rate=0.05, l2_leaf_reg=3	RMSE giảm ~4% (0.2459 → ~0.236)
LightGBM	n_estimators=1000, learning_rate=0.05, num_leaves=64, subsample=0.8	RMSE giảm ~3% (0.2577 → ~0.250)
Random Forest	n_estimators=500, max_depth=8, min_samples_leaf=2	RMSE giảm ~2% (0.2897 → ~0.284)
SVM (RBF)	kernel='rbf', C=50000, epsilon=0.1	MAE giảm ~3% (0.1584 → ~0.153)

Sau khi xác định Gradient Boosting, CatBoost và XGBoost là ba mô hình có hiệu suất cao nhất, nhóm tiến hành tối ưu hóa tham số (hyperparameter tuning) để nâng cao độ chính xác và khả năng tổng quát hóa của mô hình. Cụ thể, GridSearchCV được áp dụng cho Gradient Boosting do không gian tham số tương đối nhỏ, trong khi RandomizedSearchCV được sử dụng cho XGBoost và CatBoost với 50 lần thử ngẫu nhiên nhằm tiết kiệm thời gian khi không gian tìm kiếm lớn. Tất cả các quá trình đều được thực hiện song song và sử dụng cùng K-Fold Cross-Validation để đảm bảo tính nhất quán trong việc đánh giá hiệu suất.

Đối với Gradient Boosting, việc tăng số lượng cây ($n_estimators = 2000$) kết hợp với tốc độ học thấp hơn ($learning_rate = 0.03$) giúp mô hình học sâu hơn nhưng vẫn tránh được hiện tượng overfitting. Cấu hình $max_depth = 5$ và $subsample = 0.85$ giúp cân bằng giữa độ phức tạp và tính đa dạng của các cây, từ đó giảm RMSE khoảng 6% (từ 0.2422 xuống ~ 0.228) và cải thiện đáng kể độ chính xác dự đoán.

Đối với XGBoost, tham số $max_depth = 8$, $learning_rate = 0.05$ và $colsample_bytree = 0.8$ được lựa chọn nhằm tối ưu hóa giữa khả năng học phi tuyến và tránh đa cộng tuyến trong dữ liệu. Kết quả cho thấy RMSE giảm khoảng 5% (từ 0.2605 xuống ~ 0.247), khẳng định khả năng khái quát hóa tốt hơn. Với CatBoost, được tinh chỉnh với $depth = 8$, $learning_rate = 0.05$, $iterations = 1000$, và $l2_leaf_reg = 3$, giúp mô hình học chậm nhưng ổn định, giảm overfitting và tận dụng hiệu quả đặc trưng phân loại (categorical features). Sau tuning, RMSE giảm khoảng 4% (từ 0.2459 xuống ~ 0.236), cho thấy sự cải thiện rõ rệt trong hiệu năng dự đoán.

Nhìn chung, quá trình tối ưu hóa đã giúp ba mô hình boosting hàng đầu đạt hiệu suất cao hơn từ 3–6%, đồng thời khẳng định Gradient Boosting vẫn là mô hình đơn lẻ mạnh nhất cho bài toán dự đoán giá nhà.

Kết quả tối ưu hóa cho thấy RMSE trung bình giảm từ 3–5%, tương đương hàng nghìn USD sai lệch trong dự đoán giá nhà, đồng thời khoảng cách giữa train loss và validation loss cũng thu hẹp đáng kể, phản ánh khả năng tổng quát hóa tốt hơn. Từ đó, có thể khẳng định rằng các mô hình Boosting là lựa chọn tối ưu nhất cho bài toán này, đặc biệt khi được kết hợp với quá trình feature engineering mạnh mẽ. Trong đó, Gradient Boosting với bộ tham số tối ưu được xem là mô hình đơn lẻ hiệu quả nhất, trong khi SVM vẫn cho thấy tiềm năng về sai số tuyệt đối (MAE) nhưng kém hiệu quả về khả năng mở rộng. Bước tiếp theo, nhóm nghiên cứu sẽ xem xét ensemble (stacking) giữa GB, CatBoost và XGBoost để đạt hiệu suất cao hơn. Tất cả mô hình sau khi huấn luyện đều được lưu bằng pickle để thuận tiện cho việc tái sử dụng và dự đoán trên tập kiểm thử.

4. Kết luận

Mặc dù dự án đối mặt với nhiều thách thức từ khâu tiền xử lý dữ liệu, lựa chọn đặc trưng, đến thiết kế mô hình, nhóm nghiên cứu đã xây dựng thành công một pipeline hoàn chỉnh từ dữ liệu thô đến dự đoán cuối cùng. Các bước EDA giúp làm sáng tỏ các mối quan hệ quan trọng giữa các đặc trưng với giá nhà, đồng thời cung cấp các insight quý giá để tối ưu hóa mô hình. Việc áp dụng các kỹ thuật nâng cao, đặc biệt là Stacking Regressor, đã cải thiện đáng kể hiệu suất dự đoán, cho thấy khả năng tổng quát hóa và ổn định tốt hơn so với các phương pháp đơn lẻ.

Dự án cũng nhận diện được các giới hạn hiện tại, bao gồm sự phụ thuộc vào dữ liệu từ một khu vực cụ thể, tồn tại outliers và phân phối giá không đồng đều, cũng như thiếu các yếu tố ngoại vi có thể ảnh hưởng đến giá nhà. Những giới hạn này có thể gây ra bias hoặc ảnh hưởng đến khả năng dự đoán chính xác trên dữ liệu mới và khác biệt về bối cảnh.

Dựa trên những kết quả đã đạt được, dự án cung cấp nền tảng vững chắc cho các bài toán hồi quy thực tế, đồng thời mở ra nhiều hướng phát triển. Nhóm nghiên cứu có thể tiếp tục nâng cao độ chính xác và khả năng tổng quát hóa bằng cách tích hợp thêm các nguồn dữ liệu bên ngoài, thử nghiệm các kỹ thuật feature engineering mới, tối ưu hóa hyperparameter, hoặc mở rộng các mô hình ensemble. Những cải tiến này có tiềm năng nâng cao hiệu suất và tạo ra các dự đoán đáng tin cậy hơn trong các ứng dụng thực tế.

Tổng thể, dự án không chỉ hoàn thành mục tiêu học tập, mà còn chứng minh khả năng ứng dụng pipeline phân tích và mô hình hóa dữ liệu tabular trong lĩnh vực bất động sản, tạo cơ sở để triển khai các giải pháp dự đoán giá nhà với tính tái tạo cao và khả năng mở rộng trong tương lai.

References

- 1) Géron, A. (2022). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems (3rd ed.). O'Reilly. [BOOK] Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow 3rd - Aurélien Géron - O'Reilly - 2022.
- 2) Brownlee, J. (n.d.). Machine Learning Mastery With Python: Understand Your Data, Create Accurate Models and Work Projects End-To-End. Machine Learning Mastery. [BOOK] Machine Learning Mastery With Python Understand Your Data Create Accurate Models and Work Projects End-To-End.
- 3) Raschka, S., & Mirjalili, V. (2019). Python Machine Learning: Machine Learning and Deep Learning with Python, scikit-learn, and TensorFlow 2 (3rd ed.). Packt Publishing. [BOOK] Python Machine Learning: Machine Learning and Deep Learning with Python, scikit-learn, and TensorFlow 2 - Sebastian Raschka and Vahid Mirjalili - Packt - 2019.
- 4) James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). An Introduction to Statistical Learning: with Applications in R (1st ed.). Springer. [BOOK] An Introduction to Statistical Learning: with Applications in R - Gareth James, Daniela Witten, Trevor Hastie, and Robert Tibshirani - Springer - 2013.
- 5) McKinney, W. (2017). Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython (2nd ed.). O'Reilly Media. [BOOK] Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython - Wes McKinney - O'Reilly - 2017.
- 6) Müller, A. C., & Guido, S. (2016). Introduction to Machine Learning with Python: A Guide for Data Scientists. O'Reilly Media. [BOOK] Introduction to Machine Learning with Python: A Guide for Data Scientists - Andreas C. Müller and Sarah Guido - O'Reilly - 2016.
- 7) Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press. [BOOK] Deep Learning - Ian Goodfellow, Yoshua Bengio, and Aaron Courville - MIT Press - 2016.
- 8) Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning: Data Mining, Inference, and Prediction (2nd ed.). Springer. [BOOK] The Elements of Statistical Learning: Data Mining, Inference, and Prediction - Trevor Hastie, Robert Tibshirani, and Jerome Friedman - Springer - 2009.
- 9) VanderPlas, J. (2016). Python Data Science Handbook: Essential Tools for Working with

Data. O'Reilly Media. [BOOK] Python Data Science Handbook: Essential Tools for Working with Data - Jake VanderPlas - O'Reilly - 2016.

10) Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830. [ARTICLE] Scikit-learn: Machine Learning in Python - Fabian Pedregosa et al. - JMLR - 2011.

11) Matloff, N. (2011). The Art of R Programming: A Tour of Statistical Software Design. No Starch Press. [BOOK] The Art of R Programming: A Tour of Statistical Software Design - Norman Matloff - No Starch Press - 2011.

12) Kuhn, M., & Johnson, K. (2013). Applied Predictive Modeling. Springer. [BOOK] Applied Predictive Modeling - Max Kuhn and Kjell Johnson - Springer - 2013.

13) Bishop, C. M. (2006). Pattern Recognition and Machine Learning. Springer. [BOOK] Pattern Recognition and Machine Learning - Christopher M. Bishop - Springer - 2006.

14) Murphy, K. P. (2012). Machine Learning: A Probabilistic Perspective. MIT Press. [BOOK] Machine Learning: A Probabilistic Perspective - Kevin P. Murphy - MIT Press - 2012.

15) James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An Introduction to Statistical Learning: with Applications in Python (2nd ed.). Springer. [BOOK] An Introduction to Statistical Learning: with Applications in Python - Gareth James, Daniela Witten, Trevor Hastie, and Robert Tibshirani - Springer - 2021.

16) Raschka, S. (2015). Python Machine Learning. Packt Publishing. [BOOK] Python Machine Learning - Sebastian Raschka - Packt - 2015.

17) Grus, J. (2019). Data Science from Scratch: First Principles with Python (2nd ed.). O'Reilly Media. [BOOK] Data Science from Scratch: First Principles with Python - Joel Grus - O'Reilly - 2019.

18) Provost, F., & Fawcett, T. (2013). Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking. O'Reilly Media. [BOOK] Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking - Foster Provost and Tom Fawcett - O'Reilly - 2013.

19) Alpaydin, E. (2020). Introduction to Machine Learning (4th ed.). MIT Press. [BOOK] Introduction to Machine Learning - Ethem Alpaydin - MIT Press - 2020.

—

—

